

Examen teorico parcial 1 - Jorge Parra ITIT 13104

Link de la presentacion:

<https://canva.link/zkgcozqdp85eqh3>

Parte 1 — Demostración y explicación del pipeline ETL

Resumen del DAG ETL Mundial 2026

1. Extracción (Google Sheets)

- **Origen:** Un Google Sheet público (ID: 1pDriJ9b7K2Vnp_MP5UC2xmSkhpoZ3xN0K-r7hasD0SE) con 3 hojas:

- **Players** (GID: 1757951370)
- **Teams** (GID: 392316125)
- **Stadiums** (GID: 1508925939)

- **Mecanismo:** La función `extract()` construye URLs de exportación a CSV por cada `GID` y las lee directo con `pandas.read_csv()` sin autenticación.

2. Transformación (Limpieza y Patrón `get_or_create`)

- **Limpieza:**

- Mayúsculas y sin espacios extras en nombres de *players*.
- Conversión de `birthday` y `debut` a `datetime`.
- Renombre de la columna `group` a `group_name`.
- Eliminación de registros sin nombre.

- **Patrón `get_or_create_*`:**

- Evita duplicados buscando entidades existentes por identificador único (*code* en teams, *name* en stadiums, *nombre normalizado* en players).
- Si no existe, crea la entidad con el siguiente ID disponible; de lo contrario, retorna el ID existente.
- Mantiene una única tabla "maestra" por entidad, aunque reaparezcan en múltiples Mundiales.

3. Carga (PostgreSQL)

- **Proceso de `load_postgres()`:**


1. Ejecuta DDL para recrear el esquema `worldcup2026`.

2. Aplica `DROP TABLE` para garantización de esquema limpio.
 3. Carga los DataFrames mediante `to_sql()` respetando un orden (`TABLE_ORDER`) para no romper *foreign keys*.
- **Modelo Relacional (7 Tablas):**
 - **Maestras:** `world_cups` , `teams` , `stadiums` , `players` .
 - **Participación (Relacionales):** `team_world_cup` , `stadium_world_cup` , `player_world_cup` .
- #### 4. Conceptos Clave
- **DAG (en Airflow):** Flujo acíclico dirigido de tareas (`extract` $\rightarrow$ `transform` $\rightarrow$ `load_csv` / `load_postgres` $\rightarrow$ `notify_success`).
 - **Por qué `get_or_create`:** Evita duplicación, asegura la integridad referencial entre Mundiales, optimiza espacio y simplifica consultas analíticas mediante *joins*.

Parte 2 — 5 datos interesantes, encontrados directamente en Tableau

1. Distribución de jugadores por posición

- **Tabla principal:** `player_world_cup`
- **Campos:**
 - `position` (para agrupar por posición)
 - `player_id` (para contar jugadores únicos)
- **Join necesario:** Ninguno (todos los datos en una tabla)




2. Edad promedio de jugadores por equipo

- **Tablas:** `players` + `player_world_cup` + `teams`
- **Campos:**
 - `players.birthdate` (para calcular edad: 2022 - año de nacimiento)
 - `player_world_cup.team_id` (para vincular con equipo)
 - `teams.name` (para mostrar nombre del equipo)

- **Join:** `players.id` ↔ `player_world_cup.player_id` ↔ `teams.id`


Edad promedio de jugadores por equipo



3. Relación altura vs peso por posición

- **Tabla principal:** `player_world_cup`
- **Campos:**
 - `height` (eje X o Y)
 - `weight` (eje Y o X)
 - `position` (para colorear los puntos)
- **Join necesario:** Ninguno (todos los datos en una tabla)


Relación altura vs peso por posición



4. Distribución de equipos por grupos con estadísticas físicas

- **Tablas:** `team_world_cup` + `player_world_cup` + `teams`
- **Campos:**
 - `team_world_cup.group_name` (para agrupar por grupo A-H)
 - `player_world_cup.height` (para calcular promedio de altura)

- `player_world_cup.weight` (para calcular promedio de peso)
- `teams.name` (para mostrar nombre del equipo)
- **Join:** `team_world_cup.team_id` ↔ `player_world_cup.team_id` ↔ `teams.id`




5. Experiencia de jugadores (años desde debut) por equipo

- **Tablas:** `players` + `player_world_cup` + `teams`
- **Campos:**

- `players.debut` (para calcular experiencia: 2022 - año de debut)
- `player_world_cup.team_id` (para vincular con equipo)
- `teams.name` (para mostrar nombre del equipo)
- **Join:** `players.id` ↔ `player_world_cup.player_id` ↔ `teams.id`

Experiencia de jugadores (años desde debut) por equipo



Parte 3 — Storytelling: simulación de comentarista deportivo

Guion de Presentación: El Atleta Completo (Qatar 2022)

1. Introducción y Pregunta de Investigación

En el fútbol siempre nos hacemos las mismas preguntas: ¿quién es el mejor jugador?, ¿quién anotó más goles? o ¿quién dio más asistencias? Sin embargo, casi nadie se formula una pregunta distinta: **¿quién es el atleta genéticamente más completo del torneo?**

En este análisis dejamos de lado las métricas meritocráticas habituales para enfocar el estudio desde la biotipología, la densidad corporal, la madurez biológica y el recorrido competitivo durante el Mundial de Qatar 2022.

2. Análisis Demográfico por Posiciones

(Mostrar Gráfica 1: Distribución por posición)

Comenzamos analizando la estructura demográfica de la base de datos. Al observar el recuento de jugadores únicos por posición en 2022, vemos un volumen equilibrado dominado por mediocampistas y defensas, seguidos por delanteros y porteros. Esta distribución nos confirma que tenemos una muestra representativa para evaluar especímenes físicos en cada área del campo.

3. Madurez Biológica Colectiva

(Mostrar Gráfica 2: Edad promedio por selección)

Pasando a la madurez biológica, evaluamos la edad promedio por selección. Vemos variaciones relevantes entre plantillas muy jóvenes y selecciones veteranas, posicionándose cerca del rango de los 26 a 28 años. Este dato es crucial porque la ciencia deportiva establece los **27 años** como el punto de inflexión donde se cruzan el mayor rendimiento físico y el techo de madurez cognitiva en el fútbol.

4. Dimensiones Físicas Individuales

(Mostrar Gráfica 3: Scatter plot de Altura vs. Peso)

Para evaluar las dimensiones individuales, este mapa de dispersión cruza la estatura contra el peso de cada futbolista. La distribución por colores evidencia una clara especialización: los porteros y defensas centrales se ubican en el cuadrante superior derecho —de mayor masa y envergadura—, mientras que los atacantes de banda se concentran en zonas de menor peso para priorizar la agilidad. Esto nos demuestra que la altura por sí sola no es suficiente si no se relaciona con la densidad corporal.

5. Perfil Físico por Equipos y Grupos

(Mostrar Gráfica 4: Scatter plot de Altura vs. Peso promedio por equipo)

Elevando el análisis físico al plano colectivo, agrupamos los promedios de masa y

estatura por selección y fase de grupos. Aquí observamos cómo ciertas selecciones promedian biotipos sustancialmente más pesados y altos, mientras que otros grupos destacan por perfiles más livianos, factor que influye directamente en los estilos de juego y la resistencia al choque físico durante el torneo.

6. Jerarquía y Recorrido Internacional

(Mostrar Gráfica 5: Años de experiencia por selección)

Por último, evaluamos la jerarquía analizando los años de experiencia transcurridos desde el debut internacional de cada jugador. Las selecciones en la parte alta de la lista promedian plantillas con más de 7 u 8 años compitiendo en la élite, un factor no biomecánico pero determinante para el temple y la lectura de juego en fases eliminatorias.

7. Conclusión: El Atleta Completo Definitivo

(Mostrar Tabla / Dashboard Final)

Para unificar estas 5 dimensiones sin caer en interpretaciones aisladas, sintetizamos todas las variables en un **Score de Atleta Completo** mediante la siguiente ecuación:

$$\text{Score} = \left(\frac{\text{weight}}{\text{height}} \right) + (2022 - \text{YEAR}(\text{debut})) - |(2022 - \text{YEAR}(\text{birthday})) - 27|$$

Esta fórmula evalúa la envergadura físico-corporal, suma los años de experiencia internacional y aplica una penalización por cada año que el jugador se aleje de los 27 años de plenitud.

Al ejecutar el modelo en Tableau, el algoritmo identifica de forma automática al **Atleta Completo Definitivo del Mundial 2022: Romelu Lukaku** de la selección de **Bélgica**, liderando la tabla en el puesto **#1 con una puntuación de 59.21**. Sus 94 kg de masa corporal, 1.91 m de estatura, 29 años de edad y más de una década compitiendo en la élite representan la combinación biológica y competitiva más potente del torneo.

Jugador de Máximo Rendimiento

