

Guía de estudio Primer Parcial Teoría - Jorge Parra ITIT 13014



- **Nombre completo del alumno:** Jorge Parra Hidalgo
- **Matrícula:** 13104
- **Nombre de la materia:** Inteligencia de negocios
- **Nombre del profesor:** Luis Jorge Romo
- **Grupo y semestre:** 9no semestre
- **Fecha de entrega:** 8 de septiembre de 2026

0. Conceptos básicos de Inteligencia de Negocios

- **¿Qué es la Inteligencia de Negocios (Business Intelligence)?**

Es el conjunto de estrategias, tecnologías y procesos que transforman datos crudos en información analítica relevante para respaldar la toma de decisiones estratégicas.

- **¿Por qué es importante la Inteligencia de Negocios para una empresa u organización?**

Permite identificar ineficiencias, detectar oportunidades de mercado, optimizar procesos operativos y tomar decisiones fundamentadas en evidencia real en lugar de intuiciones.

- **¿Cuál es la diferencia entre dato, información y conocimiento?**

- **Dato:** Valor crudo sin contexto (ej. 25).
- **Información:** Dato procesado con significado y contexto (ej. 25°C de temperatura actual).
- **Conocimiento:** Información analizada y aplicada para actuar o decidir (ej. Como hace 25°C, encenderemos el aire acondicionado).

- **¿Qué tipo de preguntas o decisiones de negocio ayuda a responder la Inteligencia de Negocios?**

Preguntas descriptivas y diagnósticas sobre el pasado y el presente (ej. "¿Qué producto se vendió más el mes pasado?", "¿En qué región cayeron las ventas y por qué?").

- **¿Qué diferencia hay entre Inteligencia de Negocios y Ciencia de Datos?**

- **BI:** Se enfoca en el pasado/presente mediante datos estructurados para responder "qué pasó" y "por qué".
- **Ciencia de Datos:** Usa algoritmos avanzados, aprendizaje automático y estadísticas para predecir el futuro ("qué pasará") sobre datos estructurados y no estructurados.

1. Fundamentos de pandas

- **¿Qué es un DataFrame en pandas y en qué se diferencia de una Serie?**

Un **DataFrame** es una estructura bidimensional (tabla con filas y columnas).
Una **Serie** es una estructura unidimensional equivalente a una sola columna.

- **¿Qué función se usa para cargar un archivo Excel a un DataFrame? ¿Y para un CSV?**

- **Excel:** `pd.read_excel()`

- **CSV:** `pd.read_csv()`

- **¿Qué información te da cada uno de estos métodos: df.head(), df.shape, df.dtypes, df.info() y df.describe()?**

- `df.head()` : Muestra las primeras filas (5 por defecto).

- `df.shape` : Devuelve la tupla con las dimensiones `(filas, columnas)`.

- `df.dtypes` : Muestra el tipo de dato de cada columna.

- `df.info()` : Muestra resumen del DataFrame (filas, columnas, nulos, uso de memoria).

- `df.describe()` : Genera estadísticas descriptivas (media, min, max, cuartiles) de las columnas numéricas.

- **¿Qué es el "indexado booleano" en pandas? Investiga un ejemplo de cómo filtrar filas según una condición. Python**

Es el filtrado de datos mediante una condición lógica que evalúa a `True` o `False` para cada fila.

```
# Ejemplo: Filtrar ventas mayores a 100
df_filtrado = df[df['ventas'] > 100]
```

- **¿Qué método se usa para contar valores nulos por columna? ¿Cuál es la diferencia entre dropna() y fillna()?**

- **Contar nulos:** `df.isnull().sum()`

- **Diferencia:** `dropna()` elimina las filas o columnas que contienen nulos; `fillna()` reemplaza los valores nulos con un valor especificado.

- **¿Qué hace el método groupby() en pandas? Investiga un ejemplo que agrupe por una columna y sume otra.**Python

Agrupar los datos según las categorías de una o más columnas para aplicar una función de agregación.

```
# Ejemplo: Agrupar por categoría y sumar las ventas
df.groupby('categoria')['ventas'].sum()
```

- **¿Para qué sirve sort_values()? ¿En qué se diferencia de nlargest()?**

`sort_values()` ordena todo el DataFrame según el valor de una columna.

`nlargest()` devuelve directamente los \$N\$ registros con los valores más altos, siendo más eficiente que ordenar todo el conjunto.

2. Tipos de datos

- **¿Cuál es la diferencia entre datos cualitativos y cuantitativos?**
 - **Cualitativos:** Describen características o cualidades no numéricas.
 - **Cuantitativos:** Representan cantidades o valores numéricos medibles.
- **Dentro de los datos cualitativos, ¿qué diferencia hay entre nominal y ordinal? Investiga un ejemplo de cada uno.**
 - **Nominal:** Sin orden intrínseco (ej. *Color de ojos: Azul, Verde, Café*).
 - **Ordinal:** Tienen un orden o jerarquía lógica (ej. *Nivel académico: Primaria, Secundaria, Universidad*).
- **Dentro de los datos cuantitativos, ¿qué diferencia hay entre discreto y continuo?**
 - **Discreto:** Valores enteros contables sin valores intermedios (ej. *Número de hijos: 2*).
 - **Continuo:** Valores infinitos en un rango medible con decimales (ej. *Estatura: 1.75 m*).
- **Investiga por qué una columna como "Año", siendo numérica, en la práctica se trata como una categoría en vez de sumarse.**

Porque operarla aritméticamente (como sumar años o sacar la media) no produce un resultado de negocio coherente. El año actúa como una etiqueta temporal categórica para agrupar datos.

- **¿Qué otros tipos de datos existen, más allá de cualitativo y cuantitativo? Investiga al menos tres y da un ejemplo de cada uno.**

1. **Fechas/Tiempo (Datetime):** Registra momentos específicos (ej. `2026-09-05 14:30:00`).
2. **Booleanos:** Valores lógicos binarios (ej. `True` / `False`).
3. **Texto/String (No estructurado):** Cadenas libres de caracteres (ej. *Comentarios o reseñas de usuarios*).

3. Tableau

- **¿Cuál es la diferencia entre una dimensión y una medida en Tableau?**
 - **Dimensión:** Campos cualitativos (categorías, fechas) que segmentan o estructuran los datos.
 - **Medida:** Campos cuantitativos numéricos que se pueden agregar o calcular (sumas, promedios).
- **¿Por qué Tableau a veces clasifica mal un campo como medida cuando en realidad debería tratarse como dimensión?**

Porque Tableau detecta automáticamente que el campo contiene números (como `Código Postal` o `ID de Cliente`) e interpreta que se pueden sumar, asignándole el rol de medida.

- **Investiga la diferencia entre Workbook, Sheet, Dashboard y Story en Tableau.**
 - **Workbook:** El archivo completo (.twbx/.twb) que guarda todas las hojas y datos.
 - **Sheet (Hoja):** Espacio individual para crear una sola visualización o gráfico.
 - **Dashboard:** Lienzo interactivo que combina múltiples Hojas en una sola pantalla.

- **Story:** Secuencia ordenada de Dashboards u Hojas presentada paso a paso para contar una narrativa.
- **Si tienes varias columnas numéricas (por ejemplo, ventas por región en columnas separadas) y quieres compararlas en un solo gráfico, ¿qué mecanismo de Tableau te permite hacerlo?**

El proceso de **Pivot** (Anular dinamización de columnas) para convertirlas en dos únicas columnas: una dimensión de nombres y una medida de valores.

- **¿Qué son las Relationships en Tableau y qué reemplazaron? Investiga cómo se configuran cuando una tabla necesita conectarse con más de una tabla al mismo tiempo.**
 - Son un modelo lógico flexible de combinación de datos que reemplazó a los *Joins* físicos tradicionales.
 - Se configuran arrastrando la tabla principal al modelo de datos y arrastrando las tablas secundarias conectando líneas (*fideos*) mediante campos clave compartidos para cada relación.

4. Storytelling con datos

- **Investiga qué es el concepto de "data-ink" propuesto por Edward Tufte y qué recomienda hacer con la tinta que no representa datos.**

Es la proporción de tinta (o píxeles) usada para mostrar información real respecto al total. Tufte recomienda **eliminar o minimizar** toda la tinta que no represente datos (líneas de cuadrícula recargadas, bordes innecesarios, adornos 3D).

- **¿Qué es el "clutter" o desorden visual en un gráfico? Investiga al menos cuatro ejemplos.**

Es todo elemento visual que satura la gráfica sin aportar valor analítico:

1. Grids o cuadrículas de fondo demasiado oscuras.
2. Etiquetas de datos redundantes en cada barra.
3. Leyendas complejas cuando se pueden usar etiquetas directas.
4. Efectos decorativos 3D o sombras.

- **¿Qué son las señales pre-atencionales? Investiga al menos tres tipos.**

Son atributos visuales que el cerebro procesa de forma automática e instantánea antes de prestar atención consciente:

1. **Color:** Tono o intensidad brillante.
2. **Tamaño:** Longitud, área o grosor.
3. **Posición:** Alineación o ubicación en el espacio.

- **¿Qué estrategias existen para dirigir la atención de la audiencia hacia lo más importante de un gráfico?**

- Usar **color de contraste** únicamente en el punto focal (dejar el resto en escala de grises).
- Añadir **anotaciones directas** o texto explicativo sobre el dato clave.
- Aumentar el **tamaño o grosor** del elemento a resaltar.

5. El proceso ETL y el pipeline multi-herramienta

- **¿Qué significa la sigla ETL y qué ocurre en cada una de sus tres etapas (Extract, Transform, Load)?**

- **Extract (Extraer):** Obtención de datos crudos desde diversas fuentes (bases de datos, APIs, archivos).
- **Transform (Transformar):** Limpieza, filtrado, estructuración y aplicación de reglas de negocio a los datos.
- **Load (Cargar):** Inserción de los datos procesados en el sistema de destino (Data Warehouse, Base de Datos).

- **¿Cuál es la diferencia entre ETL y ELT?**

- **ETL:** Transforma los datos en un servidor intermedio *antes* de cargarlos al destino.
- **ELT:** Carga los datos crudos directamente en el sistema de destino y aprovecha el poder de procesamiento del destino para transformarlos ahí mismo.

- **¿Qué tipo de operaciones se hacen típicamente en la etapa de "Transform" de un proceso ETL?**

Eliminación de duplicados, imputación o borrado de nulos, estandarización de formatos de fecha, casting de tipos de datos, uniones de tablas y agregación de métricas.

- **¿Por qué conviene transformar y limpiar los datos antes de cargarlos a su destino final, en vez de cargarlos tal como llegan?**

Para asegurar la calidad e integridad de la información, evitar almacenamiento de basura (*Garbage In, Garbage Out*), mejorar el rendimiento de las consultas y mantener la seguridad/privacidad de los datos.

- **¿Qué rol cumple Apache Airflow en un pipeline de datos? ¿Transforma los datos por sí mismo, o hace otra cosa?**

Cumple el rol de **Orquestador**. No transforma los datos por sí mismo; solo programa, secuencia, coordina y monitorea la ejecución de los scripts y tareas del pipeline.

- **¿Qué es un DAG?**

Significa *Directed Acyclic Graph* (Grafo Acíclico Dirigido). Es la colección de tareas organizadas con dependencias y un orden de ejecución lineal/paralelo sin ciclos infinitos.

- **Investiga dos formas distintas de leer un Google Sheet desde pandas o Airflow. ¿Cuáles son las ventajas y desventajas de cada una?**

1. Exportación directa por URL pública (CSV):

- *Ventaja:* Simple, no requiere credenciales ni autenticación.
- *Desventaja:* El documento debe ser público; no sirve para datos sensibles.

2. API oficial de Google Sheets mediante Service Account (ej. librería `gspread`):

- *Ventaja:* Segura, permite leer y escribir en hojas privadas con permisos detallados.

- *Desventaja:* Configuración compleja (requiere llaves JSON, autenticación OAuth/Service Account).

6. Relaciona las columnas — Herramientas y conceptos clave

1. Airflow — **5** (*Orquestador de flujos de trabajo...*)
2. pandas — **2** (*Librería de Python especializada en manipular datos tabulares...*)
3. Python — **9** (*Lenguaje de programación de propósito general...*)
4. Pipeline — **11** (*Flujo completo de pasos que mueven y transforman datos...*)
5. ETL — **7** (*Proceso de tres etapas — extraer, transformar y cargar...*)
6. Tableau — **8** (*Herramienta de visualización que permite construir dashboards...*)
7. PostgreSQL — **3** (*Sistema de base de datos relacional...*)
8. Docker — **4** (*Plataforma que empaqueta una aplicación y sus dependencias...*)
9. Localhost — **10** (*Nombre que se refiere a la propia máquina...*)
10. Puerto — **6** (*Número que identifica un servicio específico dentro de una máquina...*)
11. SQL — **1** (*Lenguaje para consultar y manipular datos dentro de una base de datos...*)